

Advanced Macroeconomics Notes

Chapter 5: Discrete Time Optimization

Nerta | Fall 2025

编写于 2025 年秋季学期，仅供学习与交流参考，请勿用于商业用途。

目录

1 时间序列与差分方程基础 (Time Series & Difference Equation)	3
1.1 时间序列基础 (Time Series)	3
1.1.1 马尔可夫过程 (Markov Process)	3
1.2 差分方程与滞后算子	4
1.2.1 滞后算子 (Lag Operator L)	4
1.2.2 求解差分方程 (Solving Difference Equations)	4
2 动态规划 (Dynamic Programming)	6
2.1 有限期动态规划：吃蛋糕模型 (Cake Eating Problem)	6
2.1.1 问题设定 (Problem Setup)	6
2.1.2 拉格朗日法求解 (Lagrangian Approach)	6
2.1.3 递归法/迭代法 (Recursive Method)	7
2.1.4 逆向归纳求解步骤 (Backward Induction)	7
2.1.5 总结 (Summary)	9
2.2 一般性问题与理论基础 (General Problems)	9
2.2.1 问题描述与特征 (Problem Formulation)	9
2.2.2 贝尔曼方程的推导 (Derivation of Bellman Equation)	9
2.2.3 策略函数与理论性质 (Policy Function & Properties)	10
2.2.4 Benveniste-Scheinkman 公式	11
3 动态规划的数值解法 (Computational Methods)	12

3.1	算法原理 (Algorithms)	12
3.1.1	值函数迭代 (Value Function Iteration, VFI)	12
3.1.2	策略函数迭代 (Howard's Policy Improvement)	12
3.1.3	猜测与验证 (Guess & Verify)	13
3.2	详细例题：对数效用与 CD 生产函数	13
3.2.1	方法一：值函数迭代 (Analytical VFI)	13
3.2.2	方法二：策略函数迭代 (Policy Function Iteration)	15
3.2.3	方法三：猜测与验证 (Guess & Verify)	16
4	欧拉方程 (Euler Equation)	17
4.1	模型设定 (Model Setup)	17
4.2	三种推导方法 (Derivation Methods)	17
4.2.1	方法一：拉格朗日法 (Lagrangian Method)	17
4.2.2	方法二：代入法 (Substitution / Plug & Chug)	18
4.2.3	方法三：包络定理法 (Envelope Theorem)	19
4.3	资产定价应用 (Asset Pricing)	20
4.3.1	随机折现因子 (Stochastic Discount Factor, SDF)	20
4.3.2	风险溢价 (Risk Premium)	20
5	随机动态规划 (Stochastic DP)	21
6	卢卡斯批判 (Lucas' Critique)	21
6.1	传统计量方法的缺陷	21
6.2	卢卡斯的洞见	21
6.3	案例：投资模型	22

1 时间序列与差分方程基础 (Time Series & Difference Equation)

为什么要使用离散时间 (Why Discrete)?

- **数值计算:** 计算机无法处理连续时间, 动态模型的求解与逼近 (Numerical Approximation) 依赖离散化。
- **数据拟合:** 现实经济数据 (如 GDP、CPI) 均以离散间隔 (季度、月度) 发布, 离散模型更易于计量回归与拟合。

1.1 时间序列基础 (Time Series)

1.1.1 马尔可夫过程 (Markov Process)

随机过程是随机变量的序列。若一个过程满足“无记忆性”，即未来的概率分布仅取决于当前状态，而与过去无关，则称为马尔可夫过程。

马尔可夫性质 (Markov Property)

一个随机过程 $\{y_t\}$ 具有马尔可夫性质，如果对于所有 $k \geq 1$ 和 t ，满足：

$$f(y_{t+1} | y_t, y_{t-1}, \dots, y_{t-k}) = f(y_{t+1} | y_t) \quad (1)$$

即： y_t 包含了预测 y_{t+1} 所需的所有历史信息。

示例：一阶自回归过程 AR(1) 自回归过程 (Auto Regressive Process), 又称高斯过程 (Gaussian Process)。

$$y_{t+1} = \Phi y_t + \epsilon_{t+1}, \quad \epsilon_{t+1} \sim \text{i.i.d } N(0, \sigma^2)$$

迭代推导：

$$y_{t+2} = \Phi(\Phi y_t + \epsilon_{t+1}) + \epsilon_{t+2} = \Phi^2 y_t + \Phi \epsilon_{t+1} + \epsilon_{t+2}$$

...

$$\Phi^j y_t + \Phi^{j-1} \epsilon_{t+1} + \dots + \Phi \epsilon_{t+j-1} + \epsilon_{t+j}$$

一般项：

$$y_{t+j} = \Phi^j y_t + \sum_{k=0}^{j-1} \Phi^k \epsilon_{t+j-k}$$

条件期望： $\mathbb{E}_t[y_{t+j}] = \Phi^j y_t$ 。可以看到，一阶自回归过程具有马尔可夫性质。注：在高斯过程的假设下，期望满足无记忆性，即代表着概率分布满足无记忆性。

高阶过程的处理：AR(2) 对于 $y_{t+1} = \Phi_1 y_t + \Phi_2 y_{t-1} + \epsilon_{t+1}$ ，它依赖两期滞后，不满足一阶马尔可夫性。可以通过状态空间表达 (State Space Representation) 转化为向量 AR(1)：

$$\begin{bmatrix} y_{t+1} \\ y_t \end{bmatrix} = \begin{bmatrix} \Phi_1 & \Phi_2 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} y_t \\ y_{t-1} \end{bmatrix} + \begin{bmatrix} \epsilon_{t+1} \\ 0 \end{bmatrix}$$

令 $X_t = [y_t, y_{t-1}]'$ ，则 $X_{t+1} = AX_t + U_{t+1}$ ，恢复了马尔可夫性质。

1.2 差分方程与滞后算子

1.2.1 滞后算子 (Lag Operator L)

滞后算子是处理时间序列的基础工具，其核心定义为： $L \cdot X_t = X_{t-1}$ 。基于此定义，该算子满足以下基础运算法则：

- **幂次运算**：对于任意整数 n ，满足 $L^n X_t = X_{t-n}$ 以及 $L^{-n} X_t = X_{t+n}$ 。
- **常数运算**：算子作用于常数时保持不变，即 $L \cdot c = c$ 。

在差分方程求解中，最重要的性质是算子的**逆运算 (几何级数展开)**。这取决于参数 λ 的取值范围，分为两种情况：

1. 向后求解 (Backward looking, $|\lambda| < 1$)：当 $|\lambda| < 1$ 时，我们可以直接利用几何级数公式 $(1 - z)^{-1} = \sum z^i$ 将逆算子展开为滞后项的无穷级数：

$$\frac{1}{1 - \lambda L} X_t = (1 + \lambda L + \lambda^2 L^2 + \dots) X_t = \sum_{i=0}^{\infty} \lambda^i X_{t-i} \quad (2)$$

2. 向前求解 (Forward looking, $|\lambda| > 1$)：当 $|\lambda| > 1$ 时，上述向后展开将发散。我们需要对算子进行恒等变形，构造关于 L^{-1} (前导算子) 的级数：

$$\frac{1}{1 - \lambda L} = \frac{1}{-\lambda L(1 - \lambda^{-1} L^{-1})} = \frac{-\lambda^{-1} L^{-1}}{1 - \lambda^{-1} L^{-1}}$$

将其作用于 X_t ，得到关于未来值的加权和：

$$\frac{1}{1 - \lambda L} X_t = -\lambda^{-1} L^{-1} \sum_{i=0}^{\infty} (\lambda^{-1} L^{-1})^i X_t = -\sum_{i=0}^{\infty} \lambda^{-i-1} X_{t+i+1} \quad (3)$$

1.2.2 求解差分方程 (Solving Difference Equations)

差分方程的通解通常由两部分组成：**齐次解** (由初始条件决定) 和 **特解** (由外生驱动变量决定)。

1. 一阶差分方程 考虑方程 $y_t = \lambda y_{t-1} + a + bx_t$, 利用滞后算子可重写为 $(1 - \lambda L)y_t = a + bx_t$ 。其解的形式取决于特征根 λ 的模长:

一阶方程通解公式

通解结构为: $y_t = \underbrace{C\lambda^t}_{\text{齐次解}} + \underbrace{y_t^*}_{\text{特解}}$

- 向后求解 (Stable Case, $|\lambda| < 1$): 系统是稳定的, 当前的 y_t 取决于过去的历史冲击:

$$y_t = C\lambda^t + \frac{a}{1 - \lambda} + b \sum_{i=0}^{\infty} \lambda^i x_{t-i} \quad (4)$$

- 向前求解 (Unstable Case, $|\lambda| > 1$): 为保证解收敛, 需通过向前迭代消除爆炸项:

$$y_t = C\lambda^t + \frac{a}{1 - \lambda} - b \sum_{i=0}^{\infty} \lambda^{-i-1} x_{t+i+1} \quad (5)$$

2. 二阶差分方程 考虑方程 $y_t = \Phi_1 y_{t-1} + \Phi_2 y_{t-2} + a + bx_t$, 算子形式为:

$$(1 - \Phi_1 L - \Phi_2 L^2)y_t = a + bx_t$$

Step 1: 因式分解 (Factorization) 寻找特征根 λ_1, λ_2 使得 $(1 - \Phi_1 L - \Phi_2 L^2) = (1 - \lambda_1 L)(1 - \lambda_2 L)$ 。根据韦达定理, 参数满足:

$$\lambda_1 + \lambda_2 = \Phi_1, \quad \lambda_1 \lambda_2 = -\Phi_2$$

Step 2: 部分分式分解 (Partial Fraction Decomposition) 为了求解逆算子, 利用部分分式将其拆解为两个一阶算子之和 (假设 $\lambda_1 \neq \lambda_2$):

$$\frac{1}{(1 - \lambda_1 L)(1 - \lambda_2 L)} = \frac{1}{\lambda_1 - \lambda_2} \left(\frac{\lambda_1}{1 - \lambda_1 L} - \frac{\lambda_2}{1 - \lambda_2 L} \right) \quad (6)$$

Step 3: 求解 假设 $|\lambda_{1,2}| < 1$, 将分解后的算子作用于右侧驱动项, 即可将二阶问题转化为两个一阶问题求解:

$$y_t = c_1 \lambda_1^t + c_2 \lambda_2^t + \frac{1}{\lambda_1 - \lambda_2} \left[\lambda_1 \sum_{i=0}^{\infty} \lambda_1^i (a + bx_{t-i}) - \lambda_2 \sum_{i=0}^{\infty} \lambda_2^i (a + bx_{t-i}) \right]$$

2 动态规划 (Dynamic Programming)

2.1 有限期动态规划：吃蛋糕模型 (Cake Eating Problem)

离散动态规划 (Discrete Dynamic Programming) 总是从一个经典的吃蛋糕问题开始。

2.1.1 问题设定 (Problem Setup)

目标函数与约束：消费者需要在 0 到 T 期内规划每一期的消费量 c_t ，以最大化终身效用的现值总和。

- **目标函数 (Objective Function):**

$$\max_{\{c_t\}_{t=0}^T} \sum_{t=0}^T \beta^t u(c_t) \quad (7)$$

其中 $\beta \in (0, 1)$ 为贴现因子； $u(c)$ 满足 $u' > 0$ (边际效用为正) 且 $u'' < 0$ (边际效用递减)。

- **状态转移方程 (Transition Equation):**

$$w_{t+1} = w_t - c_t \quad (8)$$

w_t 为 t 期持有的蛋糕存量， c_t 为 t 期消费量。

- **初始与边界条件：** w_0 给定； $w_{T+1} \geq 0$ (最优解下通常假设 $w_{T+1} = 0$ ，即不留剩菜)。

2.1.2 拉格朗日法求解 (Lagrangian Approach)

在尝试递归法之前，先通过此前最熟悉的拉格朗日法求出一阶条件，确立跨期最优关系。

构造拉格朗日函数：将每一期的流量约束合并为总预算约束：

$$\sum_{t=0}^T c_t = w_0$$

。

$$\mathcal{L} = \sum_{t=0}^T \beta^t u(c_t) - \lambda \left(\sum_{t=0}^T c_t - w_0 \right)$$

一阶条件 (F.O.C.): 对任意两期 t 和 $t+1$ 的消费量求偏导：

- 对 c_t 求导: $\frac{\partial \mathcal{L}}{\partial c_t} = \beta^t u'(c_t) - \lambda = 0 \implies \lambda = \beta^t u'(c_t)$
- 对 c_{t+1} 求导: $\frac{\partial \mathcal{L}}{\partial c_{t+1}} = \beta^{t+1} u'(c_{t+1}) - \lambda = 0 \implies \lambda = \beta^{t+1} u'(c_{t+1})$

欧拉方程 (Euler Equation)

联立上述两式消去 λ ，得到跨期消费的最优路径条件：

$$u'(c_t) = \beta u'(c_{t+1}) \quad (9)$$

经济学含义：当期消费的边际效用，应该等于下一期消费的边际效用的贴现值。这是动态优化的核心均衡条件。

2.1.3 递归法/迭代法 (Recursive Method)

对于有限期问题，利用值函数 (Value Function) 将 $T+1$ 期的问题简化为一系列的“两期”问题（当期 vs 未来）。

值函数定义：定义 $V(w_\tau)$ 为从第 τ 期开始，拥有存量 w_τ 时所能获得的最大化累积效用：

$$V(w_\tau) = \max_{\{c_t\}_{t=\tau}^T} \sum_{t=\tau}^T \beta^{t-\tau} u(c_t) \quad \text{s.t.} \quad w_{t+1} = w_t - c_t$$

利用状态转移 $w_{\tau+1} = w_\tau - c_\tau$ ，将求和项拆分为“当期效用”与“未来最大化效用”：

$$\begin{aligned} V(w_\tau) &= \max_{c_\tau} \left[u(c_\tau) + \sum_{t=\tau+1}^T \beta^{t-\tau} u(c_t) \right] \\ &= \max_{c_\tau} \left[u(c_\tau) + \beta \max_{\{c_t\}_{t=\tau+1}^T} \sum_{t=\tau+1}^T \beta^{t-\tau-1} u(c_t) \right] \end{aligned}$$

最终得到贝尔曼方程：

贝尔曼方程 (Bellman Equation)

$$V(w_\tau) = \max_{c_\tau} \{u(c_\tau) + \beta V(w_{\tau+1})\} \quad (10)$$

约束条件为： $w_{\tau+1} = w_\tau - c_\tau$ 。

2.1.4 逆向归纳求解步骤 (Backward Induction)

求解动态规划问题的核心在于“逆向思维”。由于当前的决策依赖于对未来的预期价值，我们需要从时间的终点（一切都已确定）开始，逐步向前推导，直到初始时刻。

第一步：终值时刻 ($t = T$) 在最后一期，消费者面临的问题是最大化当期效用：

$$V_T(w_T) = \max_{c_T} u(c_T) \quad \text{s.t.} \quad 0 \leq c_T \leq w_T$$

由于这是最后一期，任何剩余的蛋糕 w_{T+1} 都没有价值（假设没有遗赠动机）。理性的消费者会选择吃光所有存量。因此，最优策略和值函数分别为：

$$c_T^* = w_T, \quad V_T(w_T) = u(w_T) \quad (11)$$

这里有一个关键的性质：最后一期财富的边际价值，直接等于最后一期消费的边际效用：

$$V_T'(w_T) = u'(c_T^*)$$

注：这一性质会在后面一般性问题中详细推导。被称为包络定理或 $B-S$ 公式。

第二步：倒数第二期 ($t = T-1$) 此时，消费者知道下一期(T 期)的值函数是 $V_T(w_T) = u(w_T)$ 。优化问题变为：

$$V_{T-1}(w_{T-1}) = \max_{c_{T-1}} \{u(c_{T-1}) + \beta V_T(\underbrace{w_{T-1} - c_{T-1}}_{w_T})\}$$

这是一个单变量无约束极值问题。对 c_{T-1} 求一阶导数 (F.O.C.):

$$u'(c_{T-1}) + \beta V_T'(w_T) \cdot \frac{dw_T}{dc_{T-1}} = 0$$

由于 $\frac{dw_T}{dc_{T-1}} = -1$ ，方程整理为：

$$u'(c_{T-1}) = \beta V_T'(w_T)$$

关键代换：利用第一步得到的性质 $V_T'(w_T) = u'(c_T^*)$ ，我们直接得到欧拉方程：

$$u'(c_{T-1}) = \beta u'(c_T^*) \quad (12)$$

该方程解出了最优策略 $c_{T-1}^* = h_{T-1}(w_{T-1})$ 。

第三步：一般性递推 (任意 t 期) 假设我们已经解出了 $t+1$ 期的值函数 $V_{t+1}(w_{t+1})$ ，且已知其导数性质 $V_{t+1}'(w_{t+1}) = u'(c_{t+1}^*)$ 。 t 期的优化问题为：

$$\max_{c_t} \{u(c_t) + \beta V_{t+1}(w_t - c_t)\}$$

一阶条件要求：

$$u'(c_t) = \beta V_{t+1}'(w_{t+1})$$

再次利用后一期的边际价值性质，将其替换为边际效用：

$$u'(c_t) = \beta u'(c_{t+1}^*) \quad (13)$$

这表明：在最优路径上，当期消费的边际效用等于下一期最优消费边际效用的折现值。

第四步：初始时刻 ($t = 0$) 通过上述递推，我们得到了一系列欧拉方程：

$$u'(c_0) = \beta u'(c_1) = \beta^2 u'(c_2) = \cdots = \beta^T u'(c_T)$$

结合总资源约束 $\sum_{t=0}^T c_t = w_0$ ，我们便可以解出唯一的初始消费 c_0^* 以及整个最优消费路径。

2.1.5 总结 (Summary)

方法总结

- 递归法通过贝尔曼方程 $V(w_t) = \max\{u(c_t) + \beta V(w_{t+1})\}$ 将多期规划转化为了连续的“两期权衡”问题。
- 有限期动态规划通常采用逆向归纳 (Backward Induction), 即 $T \rightarrow T-1 \rightarrow \cdots \rightarrow 0$ 。
- (Policy Function) $c_t = h_t(w_t)$ ，告诉我们在任意时间 t ，给定手头的存量 w_t ，应该消费多少。

2.2 一般性问题与理论基础 (General Problems)

2.2.1 问题描述与特征 (Problem Formulation)

上述逆向迭代法受限于有限期的特征，我们将无限期动态规划的一般问题描述为寻找一个控制变量序列 $\{u_t\}_{t=0}^{\infty}$ ，以最大化贴现回报的总和：

$$\max_{\{u_t\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t r(x_t, u_t) \quad (14)$$

其受限于状态转移方程 $x_{t+1} = g(x_t, u_t)$ ，且初始状态 x_0 给定。

该问题的构建基于两个显著的假设特征。

- 首先是状态充分性 (State Sufficiency)，意味着当前状态变量 x_t 包含了过去所有决策中对未来有用的信息，决策者仅需依据 x_t 即可做出最优选择。
- 其次是时间无关性 (Time Invariance)，即回报函数 $r(\cdot)$ 和状态转移函数 $g(\cdot)$ 的形式不随时间 t 变化，仅依赖于状态和控制变量本身。

2.2.2 贝尔曼方程的推导 (Derivation of Bellman Equation)

为了求解上述无限期问题，我们需要定义值函数 (Value Function) $V(x_0)$ ，它表示从初始状态 x_0 开始，采取最优决策序列所能获得的最大化贴现回报总和。

通过利用目标函数的递归性质，我们可以推导如下：

$$\begin{aligned}
V(x_0) &= \max_{\{u_t\}} \sum_{t=0}^{\infty} \beta^t r(x_t, u_t) \\
&= \max_{u_0} \left\{ r(x_0, u_0) + \sum_{t=1}^{\infty} \beta^t r(x_t, u_t) \right\} \\
&= \max_{u_0} \left\{ r(x_0, u_0) + \beta \sum_{t=1}^{\infty} \beta^{t-1} r(x_t, u_t) \right\}
\end{aligned} \tag{15}$$

观察上式括号内的求和项，本质上是从 $t = 1$ 时刻的状态 x_1 开始的同一最优化问题，即 $V(x_1)$ 。因此，我们可以将问题转化为递归形式：

$$V(x_0) = \max_{u_0} \{r(x_0, u_0) + \beta V(x_1)\}$$

去掉时间下标，令 x 表示当前状态， x' 表示下一期状态，我们得到了著名的贝尔曼方程 (Bellman Equation)：

$$V(x) = \max_u \{r(x, u) + \beta V(x')\} \quad \text{s.t.} \quad x' = g(x, u) \tag{16}$$

2.2.3 策略函数与理论性质 (Policy Function & Properties)

我们的核心任务是寻找两个函数：值函数 $V(x)$ 和策略函数 (Policy Function) $h(x)$ 。

策略函数定义了给定状态 x 下的最优决策规则，即 $u = h(x)$ 。将其代入贝尔曼方程，我们得到一个关于 V 和 h 的泛函方程，其解被称为递归解：

$$V(x) = r(x, h(x)) + \beta V(g(x, h(x)))$$

为了保证最优化问题表现良好 (Well-behaved)，通常需要满足一定的正则条件：回报函数 $r(\cdot)$ 需为有界凹函数，且由 $g(\cdot)$ 生成的约束集需为紧凸集。

在满足这些条件时，理论上可以证明：

- 贝尔曼方程存在唯一的、严格凹的解 $V(x)$ ；
- 从任意有界连续的初始猜测 V_0 开始，通过值函数迭代 $V_{j+1}(x) = \max_u \{r(x, u) + \beta V_j(x')\}$ 得到序列必收敛于真实值函数。
- 存在唯一且时间不变的最优策略函数 $h(x)$ 。
- 值函数 $V(x)$ 是可微的。并且满足 B-S 公式： $V'(x) = \frac{\partial r}{\partial x} + \beta V'(g(\cdot)) \frac{\partial g}{\partial x}$

2.2.4 Benveniste-Scheinkman 公式

值函数的可微性对于后续推导欧拉方程至关重要。Benveniste-Scheinkman 公式提供了计算值函数导数的捷径。

定理：Benveniste-Scheinkman 公式

结论：值函数对状态变量的导数，等于当期回报函数对状态变量的偏导，加上未来价值对状态的直接影响。

$$V'(x) = \frac{\partial r}{\partial x} + \beta V'(x') \frac{\partial g}{\partial x} \quad (17)$$

证明 (Proof)：考虑代入了最优策略函数 $h(x)$ 后的值函数恒等式：

$$V(x) = r(x, h(x)) + \beta V(g(x, h(x)))$$

我们需要对状态变量 x 求全导数。根据链式法则，状态 x 的变化不仅直接影响 r 和 g ，还会通过改变最优决策 $h(x)$ 产生间接影响。展开如下：

$$V'(x) = \frac{\partial r}{\partial x} + \frac{\partial r}{\partial h} \frac{\partial h}{\partial x} + \beta V'(x') \left[\frac{\partial g}{\partial x} + \frac{\partial g}{\partial h} \frac{\partial h}{\partial x} \right] \quad (18)$$

将同类项合并，我们将包含 $\frac{\partial h}{\partial x}$ (即策略调整项) 的部分归为一组：

$$V'(x) = \underbrace{\left[\frac{\partial r}{\partial x} + \beta V'(x') \frac{\partial g}{\partial x} \right]}_{\text{直接效应}} + \underbrace{\left[\frac{\partial r}{\partial h} + \beta V'(x') \frac{\partial g}{\partial h} \right]}_{\text{间接效应 (包络项)}} \cdot \frac{\partial h}{\partial x} \quad (19)$$

回顾贝尔曼方程的原始优化问题，由于 $u = h(x)$ 是最优解（内点解），根据一阶条件 (F.O.C.)，目标函数对控制变量 u 的导数必须为零：

$$\frac{\partial r}{\partial u} + \beta V'(x') \frac{\partial g}{\partial u} = 0$$

注意公式中的 u 即对应 h 。因此，上述全导数公式中，中括号内的“间接效应”项恒等于零。这一性质被称为**包络定理**。

最终，我们消去了含有策略导数 $\frac{\partial h}{\partial x}$ 的项，得到简洁的公式：

$$V'(x) = \frac{\partial r}{\partial x} + \beta V'(g(x, h(x))) \frac{\partial g}{\partial x}$$

证毕。

3 动态规划的数值解法 (Computational Methods)

本节详细介绍求解动态规划问题的三种核心方法。我们的目标是寻找满足贝尔曼方程的值函数 $V(x)$ 和策略函数 $h(x)$:

$$V(x) = \max_u \{r(x, u) + \beta V(g(x, u))\}$$

3.1 算法原理 (Algorithms)

3.1.1 值函数迭代 (Value Function Iteration, VFI)

核心思想: 将贝尔曼方程视为一个算子 T , 通过不断迭代 $V_{j+1} = TV_j$ 逼近不动点。

1. **初始化 (Initialization):** 猜测一个初始值函数 $V_0(x)$ (通常设为 $V_0(x) = 0$ 或其他有界函数)。
2. **迭代 (Iteration):** 对于第 j 次迭代得到的 $V_j(x)$, 通过求解右侧最大化问题计算 $V_{j+1}(x)$:

$$V_{j+1}(x) = \max_u \{r(x, u) + \beta V_j(g(x, u))\} \quad (20)$$

3. **终止 (Termination):** 计算两个函数之间的距离 (通常使用上确界范数 $\|\cdot\|_\infty$)。当 $\|V_{j+1} - V_j\| < \epsilon$ 时停止迭代。根据压缩映射定理 (Contraction Mapping Theorem), 该算法保证收敛。

3.1.2 策略函数迭代 (Howard's Policy Improvement)

核心思想: 直接在策略空间进行迭代。通常比 VFI 收敛更快, 因为它在每一步都利用了无限期的价值信息。

1. **初始化:** 猜测一个可行的策略函数 $u = h_0(x)$ 。
2. **策略评估 (Policy Evaluation):** 计算当前策略 h_j 对应的终身价值 $V_{h_j}(x)$ 。这需要计算无穷级数:

$$V_{h_j}(x) = \sum_{t=0}^{\infty} \beta^t r(x_t, h_j(x_t)) \quad \text{s.t. } x_{t+1} = g(x_t, h_j(x_t)) \quad (21)$$

3. **策略改进 (Policy Improvement):** 基于当前的估值 V_{h_j} , 寻找一个能最大化单期贝尔曼方程的新策略 h_{j+1} :

$$h_{j+1}(x) = \arg \max_u \{r(x, u) + \beta V_{h_j}(g(x, u))\} \quad (22)$$

4. **终止:** 若 $h_{j+1}(x) \approx h_j(x)$, 则停止。

3.1.3 猜测与验证 (Guess & Verify)

核心思想：适用于能够获得解析解的特定模型（如 CRRA 效用 + Cobb-Douglas 生产函数）。

1. 根据模型结构猜测 $V(x)$ 的函数形式（包含待定系数）。
2. 代入贝尔曼方程求解 F.O.C.，得到策略函数。
3. 代回原方程，通过系数匹配 (Matching Coefficients) 解出待定系数。

3.2 详细例题：对数效用与 CD 生产函数

模型设定 (Model Setup):

- 效用函数： $u(c) = \ln c$
- 生产函数： $y = Ak^\alpha$ （假设完全折旧 $\delta = 1$ ）
- 资源约束： $k' = y - c = Ak^\alpha - c$
- 贝尔曼方程：

$$V(k) = \max_{k'} \{ \ln(Ak^\alpha - k') + \beta V(k') \} \quad (23)$$

我们将分别使用三种方法详细求解该模型。

3.2.1 方法一：值函数迭代 (Analytical VFI)

虽然 VFI 通常用于数值计算，但在这个例子中我们可以手动推导迭代过程，观察其收敛规律。

迭代 1 (Iteration 1):

- **猜测：** $V_0(k) = 0$ 。
- **更新：** $V_1(k) = \max_c \{ \ln c + \beta \cdot 0 \} = \max_c \ln c$ 。
- **解：**消费者会吃光所有资源，即 $c^* = Ak^\alpha$ 。
- **结果：** $V_1(k) = \ln(Ak^\alpha) = \ln A + \alpha \ln k$ 。

迭代 2 (Iteration 2):

- **更新：**将 $V_1(k)$ 代入贝尔曼方程右侧：

$$V_2(k) = \max_c \{ \ln c + \beta (\ln A + \alpha \ln k') \}$$

$$\text{s.t. } k' = Ak^\alpha - c$$

$$V_2(k) = \max_c \{ \ln c + \beta \ln A + \alpha \beta \ln(Ak^\alpha - c) \}$$

- **F.O.C.:** 对 c 求导:

$$\frac{1}{c} + \alpha\beta \frac{1}{Ak^\alpha - c}(-1) = 0 \implies Ak^\alpha - c = \alpha\beta c$$

$$c^* = \frac{1}{1 + \alpha\beta} Ak^\alpha$$

- **结果:** 这意味着最优储蓄 $k' = \frac{\alpha\beta}{1 + \alpha\beta} Ak^\alpha$ 。代回计算 V_2 :

$$\begin{aligned} V_2(k) &= \ln c^* + \beta \ln A + \alpha\beta \ln k' \\ &= \ln \left(\frac{1}{1 + \alpha\beta} Ak^\alpha \right) + \text{Const} + \alpha\beta \ln \left(\frac{\alpha\beta}{1 + \alpha\beta} Ak^\alpha \right) \end{aligned}$$

关注 $\ln k$ 的系数: 第一项贡献 α , 第三项贡献 $\alpha\beta \cdot \alpha = \alpha^2\beta$ 。

$$V_2(k) = (\alpha + \alpha^2\beta) \ln k + \text{Constants}$$

迭代 3 (Iteration 3):

- **更新:** $V_3(k) = \max_c \{ \ln c + \beta [(\alpha + \alpha^2\beta) \ln k' + \text{Const}] \}$ 。
- **F.O.C.:** 令 $B = \alpha + \alpha^2\beta$ 。

$$\frac{1}{c} = \frac{\beta B}{Ak^\alpha - c} \implies c^* = \frac{1}{1 + \beta B} Ak^\alpha$$

代入 B :

$$c^* = \frac{1}{1 + \alpha\beta + (\alpha\beta)^2} Ak^\alpha$$

收敛 (Convergence): 随着迭代次数 $j \rightarrow \infty$, 分母呈现几何级数求和的形式:

$$1 + \alpha\beta + (\alpha\beta)^2 + \dots = \frac{1}{1 - \alpha\beta}$$

因此, 收敛后的策略函数为:

$$c^* = \frac{1}{\frac{1}{1 - \alpha\beta}} Ak^\alpha = (1 - \alpha\beta) Ak^\alpha \quad (24)$$

即最优消费是产出的 $(1 - \alpha\beta)$ 份额, 最优储蓄率为 $s = \alpha\beta$ 。

3.2.2 方法二：策略函数迭代 (Policy Function Iteration)

Step 1: 初始化 (Initialization) 猜测一个线性策略：消费是产出的固定比例 γ 。

$$c = h_0(k) = \gamma A k^\alpha, \quad \gamma \in (0, 1)$$

这意味着资本积累路径为：

$$k_{t+1} = A k_t^\alpha - \gamma A k_t^\alpha = (1 - \gamma) A k_t^\alpha$$

令 $s_0 = 1 - \gamma$ ，对两边取对数：

$$\ln k_{t+1} = \ln(s_0 A) + \alpha \ln k_t$$

Step 2: 策略评估 (Policy Evaluation) 计算该策略下的值函数 $V_{h_0}(k_0) = \sum_{t=0}^{\infty} \beta^t \ln c_t$ 。

$$\ln c_t = \ln(\gamma A k_t^\alpha) = \ln(\gamma A) + \alpha \ln k_t$$

我们需要计算 $\sum \beta^t \alpha \ln k_t$ 。利用递推关系 $\ln k_t = \text{Const} + \alpha^t \ln k_0$ ，代入求和：

$$\begin{aligned} \text{与 } k_0 \text{ 相关的项} &= \alpha \ln k_0 + \beta \alpha (\alpha \ln k_0) + \beta^2 \alpha (\alpha^2 \ln k_0) + \dots \\ &= \alpha (1 + \alpha \beta + (\alpha \beta)^2 + \dots) \ln k_0 = \frac{\alpha}{1 - \alpha \beta} \ln k_0 \end{aligned}$$

因此，值函数形式为：

$$V_{h_0}(k) = \frac{\alpha}{1 - \alpha \beta} \ln k + \text{Constant}_{h_0} \quad (25)$$

Step 3: 策略改进 (Policy Improvement) 基于 $V_{h_0}(k)$ 寻找新策略 $h_1(k)$ 。

$$h_1(k) = \arg \max_{k'} \{ \ln(A k^\alpha - k') + \beta \left(\frac{\alpha}{1 - \alpha \beta} \ln k' \right) \}$$

这是一个关于 k' 的优化问题。求解 F.O.C.：

$$\begin{aligned} \frac{-1}{A k^\alpha - k'} + \beta \frac{\alpha}{1 - \alpha \beta} \frac{1}{k'} &= 0 \\ \frac{1}{c} &= \frac{\alpha \beta}{1 - \alpha \beta} \frac{1}{k'} \implies k' = \frac{\alpha \beta}{1 - \alpha \beta} c \end{aligned}$$

结合 $c + k' = A k^\alpha$ ：

$$c \left(1 + \frac{\alpha \beta}{1 - \alpha \beta} \right) = A k^\alpha \implies c \left(\frac{1}{1 - \alpha \beta} \right) = A k^\alpha$$

解得新策略：

$$c^* = (1 - \alpha\beta)Ak^\alpha \quad (26)$$

这与 VFI 方法得到的最终结果完全一致。这意味着只需一次策略改进，我们就找到了最优解（这是 Log Utility 模型的特殊性质，通常需要多次迭代）。

3.2.3 方法三：猜测与验证 (Guess & Verify)

这是解析求解最常用的方法。

Step 1: 猜测观察效用函数和生产函数形式，猜测值函数为：

$$V(k) = E + F \ln k$$

Step 2: 求解 RHS 最大化

$$\max_{k'} \{ \ln(Ak^\alpha - k') + \beta(E + F \ln k') \}$$

F.O.C. 对 k' :

$$\frac{-1}{Ak^\alpha - k'} + \frac{\beta F}{k'} = 0 \implies k' = \frac{\beta F}{1 + \beta F} Ak^\alpha$$

Step 3: 代回验证与系数匹配将最优 k' 代入贝尔曼方程：

$$E + F \ln k = \ln \left(\frac{1}{1 + \beta F} Ak^\alpha \right) + \beta E + \beta F \ln \left(\frac{\beta F}{1 + \beta F} Ak^\alpha \right)$$

整理等式右边，提取所有含 $\ln k$ 的项：

$$\text{RHS} = \text{Const} + \ln(k^\alpha) + \beta F \ln(k^\alpha)$$

$$\text{RHS} = \text{Const} + (\alpha + \alpha\beta F) \ln k$$

令左右两边 $\ln k$ 的系数相等：

$$F = \alpha + \alpha\beta F \implies F = \frac{\alpha}{1 - \alpha\beta}$$

Step 4: 求解最优策略将 F 代回 k' 的表达式：

$$\text{储蓄率 } s = \frac{\beta F}{1 + \beta F} = \frac{\frac{\alpha\beta}{1 - \alpha\beta}}{1 + \frac{\alpha\beta}{1 - \alpha\beta}} = \alpha\beta$$

因此，最优资本积累路径为 $k' = \alpha\beta Ak^\alpha$ ，最优消费为 $c = (1 - \alpha\beta)Ak^\alpha$ 。

4 欧拉方程 (Euler Equation)

欧拉方程是宏观经济学和金融学的核心基石，它描述了消费者在跨期优化中，如何权衡“现在消费”与“未来消费”。其核心直觉是：在最优路径上，消费者对于将一单位资源用于当期消费还是留给未来的边际效用是相等的。

4.1 模型设定 (Model Setup)

考虑一个标准的无限期消费-储蓄问题：

- **目标函数:** $\max \sum_{t=0}^{\infty} \beta^t u(c_t)$
- **预算约束:** $A_{t+1} = (1 + r_t)(A_t + y_t - c_t)$
- **状态变量:** A_t (财富/资产); **控制变量:** c_t (消费)。

4.2 三种推导方法 (Derivation Methods)

4.2.1 方法一：拉格朗日法 (Lagrangian Method)

这是最标准、最通用的求解方法。

步骤: 1. 构造无穷期拉格朗日函数，引入乘子序列 $\{\lambda_t\}_{t=0}^{\infty}$ ：

$$\mathcal{L} = \sum_{t=0}^{\infty} \beta^t u(c_t) + \sum_{t=0}^{\infty} \lambda_t [(1 + r_t)(A_t + y_t - c_t) - A_{t+1}]$$

2. 求解一阶条件 (F.O.C.):

$$\frac{\partial \mathcal{L}}{\partial c_t} = \beta^t u'(c_t) - \lambda_t(1 + r_t) = 0 \quad \Rightarrow \quad \lambda_t = \frac{\beta^t u'(c_t)}{1 + r_t} \quad (1)$$

$$\frac{\partial \mathcal{L}}{\partial A_{t+1}} = -\lambda_t + \lambda_{t+1}(1 + r_{t+1}) = 0 \quad \Rightarrow \quad \lambda_t = \lambda_{t+1}(1 + r_{t+1}) \quad (2)$$

注意: 此处我们在 t 期对 A_{t+1} 求导。式 (2) 中的第二项来源于 $t+1$ 期的约束项 $\lambda_{t+1}(1+r_{t+1})A_{t+1}$ 。

3. 联立求解: 将 (1) 式代入 (2) 式消除 λ :

$$\frac{\beta^t u'(c_t)}{1 + r_t} = \frac{\beta^{t+1} u'(c_{t+1})}{1 + r_{t+1}} (1 + r_{t+1})$$

化简即得欧拉方程:

$$u'(c_t) = \beta(1 + r_t)u'(c_{t+1}) \quad (27)$$

4.2.2 方法二：代入法 (Substitution / Plug & Chug)

该方法的核心思想是将约束条件直接代入贝尔曼方程，将其转化为关于状态变量的无约束极值问题，并通过严谨的微积分推导得出欧拉方程。

1. 准备工作由预算约束 $A_{t+1} = (1 + r_t)(A_t + y_t - c_t)$ ，反解出消费：

$$c_t = A_t + y_t - \frac{A_{t+1}}{1 + r_t}$$

代入贝尔曼方程：

$$V(A_t) = \max_{A_{t+1}} \left\{ u \left(\underbrace{A_t + y_t - \frac{A_{t+1}}{1 + r_t}}_{c_t} \right) + \beta V(A_{t+1}) \right\}$$

2. 求解一阶条件 (F.O.C.) 我们需要选择最优的 A_{t+1} 来最大化右侧表达式。对决策变量 A_{t+1} 求偏导并令其为 0：

$$\frac{\partial}{\partial A_{t+1}} \left(u(c_t) + \beta V(A_{t+1}) \right) = 0$$

利用链式法则：

$$u'(c_t) \cdot \frac{\partial c_t}{\partial A_{t+1}} + \beta V'(A_{t+1}) = 0$$

由于 $\frac{\partial c_t}{\partial A_{t+1}} = -\frac{1}{1+r_t}$ ，代入得：

$$u'(c_t) \cdot \left(-\frac{1}{1+r_t} \right) + \beta V'(A_{t+1}) = 0$$

整理得到关键等式 (Eq.1)：

$$\frac{u'(c_t)}{1+r_t} = \beta V'(A_{t+1}) \quad (\text{Eq.1})$$

3. 计算值函数的导数 (Deriving V') 为了消除 (Eq.1) 中的未知项 $V'(A_{t+1})$ ，我们需要计算 $V'(A_t)$ 。假设最优策略函数为 $A_{t+1}^* = h(A_t)$ ，将其代回贝尔曼方程，得到恒等式：

$$V(A_t) = u \left(A_t + y_t - \frac{h(A_t)}{1+r_t} \right) + \beta V(h(A_t))$$

对状态变量 A_t 求全导数：

$$V'(A_t) = u'(c_t) \cdot \left(1 - \frac{h'(A_t)}{1+r_t} \right) + \beta V'(h(A_t)) \cdot h'(A_t)$$

将含有 $h'(A_t)$ (策略调整项) 的项合并:

$$V'(A_t) = u'(c_t) + h'(A_t) \cdot \underbrace{\left[-\frac{u'(c_t)}{1+r_t} + \beta V'(A_{t+1}) \right]}_{\text{由 (Eq.1) 可知此项为 0}}$$

由于括号内的项正是 F.O.C. 的结果, 其值为 0 (包络定理的核心), 因此:

$$V'(A_t) = u'(c_t) \quad (\text{Eq.2})$$

数学含义: 增加一单位财富的边际价值, 严格等于将其用于当期消费的边际效用。

4. **联立求解** 将 (Eq.2) 的逻辑向后推一期, 可得:

$$V'(A_{t+1}) = u'(c_{t+1})$$

将其代入 (Eq.1):

$$\frac{u'(c_t)}{1+r_t} = \beta u'(c_{t+1})$$

整理即得欧拉方程:

$$u'(c_t) = \beta(1+r_t)u'(c_{t+1}) \quad (28)$$

4.2.3 方法三: 包络定理法 (Envelope Theorem)

这是最简洁的方法, 直接利用动态规划的性质。

1. **F.O.C. (对 c_t):** 在贝尔曼方程 $V(A_t) = \max\{u(c_t) + \beta V(A_{t+1})\}$ 中:

$$u'(c_t) = \beta V'(A_{t+1}) \frac{\partial A_{t+1}}{\partial c_t} \cdot (-1)$$

由于 A_{t+1} 对 c_t 的导数由预算约束决定 ($\partial A_{t+1} / \partial c_t = -(1+r_t)$), 修正符号后:

$$u'(c_t) = \beta(1+r_t)V'(A_{t+1}) \quad (*1)$$

2. **包络条件 (对 A_t):**

$$V'(A_t) = \frac{\partial}{\partial A_t} [u(c_t) + \beta V(A_{t+1})] = \beta V'(A_{t+1})(1+r_t)$$

结合 (*1) 可知: $V'(A_t) = u'(c_t)$ 。

3. **代换:** 将 $V'(A_{t+1}) = u'(c_{t+1})$ 代回 (*1), 即得证。

4.3 资产定价应用 (Asset Pricing)

当引入不确定性时, 未来的消费 c_{t+1} 和资产回报 R_{t+1} 都是随机变量, 欧拉方程变为期望形式:

$$u'(c_t) = \beta \mathbb{E}_t[(1 + R_{t+1})u'(c_{t+1})] \quad (29)$$

4.3.1 随机折现因子 (Stochastic Discount Factor, SDF)

定义 m_{t+1} 为跨期边际替代率 (IMRS):

SDF / Pricing Kernel

$$m_{t+1} \equiv \beta \frac{u'(c_{t+1})}{u'(c_t)}$$

利用 SDF, 所有资产定价公式可统一写为:

$$1 = \mathbb{E}_t[m_{t+1}R_{t+1}] \quad \text{或} \quad P_t = \mathbb{E}_t[m_{t+1}X_{t+1}] \quad (30)$$

其中 X_{t+1} 是资产在下一期的总得益 (Payoff)。

4.3.2 风险溢价 (Risk Premium)

利用协方差公式 $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y) + Cov(X, Y)$ 展开定价方程:

$$1 = \mathbb{E}_t[m_{t+1}]\mathbb{E}_t[R_{t+1}] + Cov_t(m_{t+1}, R_{t+1})$$

1. 无风险利率 (R_f): 对于无风险资产, Cov 为 0, 因此:

$$1 = \mathbb{E}_t[m_{t+1}]R_f \implies R_f = \frac{1}{\mathbb{E}_t[m_{t+1}]}$$

2. 风险资产期望回报: 代入 R_f 表达式:

$$1 = \frac{\mathbb{E}_t[R_{t+1}]}{R_f} + Cov_t(m_{t+1}, R_{t+1})$$

整理得风险溢价公式:

风险溢价 (Risk Premium)

$$\mathbb{E}_t[R_{t+1}] - R_f = -R_f Cov_t(m_{t+1}, R_{t+1}) \quad (31)$$

直觉解释 (Intuition):

- **负相关 ($\text{Cov} < 0$):** 大多数资产 (如股票) 的回报与 SDF 负相关。
 - 经济好 $\rightarrow$ 消费 $c \uparrow \rightarrow$ 边际效用 $u' \downarrow \rightarrow$ SDF $m \downarrow$ 。
 - 此时股票回报 R 通常较高。
 - 即 R 与 m 负相关, 公式右边为正。投资者要求**正的风险溢价**来补偿这种“锦上添花”的特性。
- **正相关 ($\text{Cov} > 0$):** “保险”类资产。
 - 经济差 $\rightarrow c \downarrow \rightarrow$ SDF $m \uparrow$ 。
 - 如果某资产此时能提供高回报 (如黄金、看跌期权), 它就是“雪中送炭”。
 - 此时溢价为负, 投资者愿意接受低于无风险利率的回报来持有它。

5 随机动态规划 (Stochastic DP)

引入随机冲击 ϵ , 贝尔曼方程变为期望形式:

$$V(x) = \max_u \{r(x, u) + \beta \mathbb{E}[V(g(x, u, \epsilon)) | x]\}$$

求解逻辑与确定性情形一致, 只是在迭代时需计算期望值。B-S 公式同样适用 (需加期望算子)。

6 卢卡斯批判 (Lucas' Critique)

6.1 传统计量方法的缺陷

20 世纪 60 年代的宏观计量模型通常估计如下形式的“简化参数”方程:

$$y_{t+1} = \Theta y_t + \Gamma x_t + \epsilon_t$$

其中 x_t 是政策变量。传统观点错误地假设参数 Θ, Γ 是结构性的, 不随政策规则变化。

6.2 卢卡斯的洞见

卢卡斯指出, 经济主体的决策规则 (如消费函数、投资函数) 取决于其对未来政策的预期。当政策规则改变时, 预期的形成方式改变, 导致个人的最优决策规则改变, 进而导致宏观方程中的简化参数 Θ, Γ 发生跳变。

深层参数 (Deep Parameters)

只有偏好 (β, ρ) 、技术 (α, δ) 等参数是不变的。政策分析必须基于这些深层参数构建结构化模型。

6.3 案例：投资模型

假设资本积累方程依赖于对未来税率 τ 的预期：

$$k_t = \lambda k_{t-1} - \alpha \sum_{j=0}^{\infty} \delta^j \mathbb{E}_t[\tau_{t+j}]$$

假设政府的税收政策规则为 $\tau_{t+1} = \theta \tau_t$ (θ 为政策参数)。理性预期下， $\mathbb{E}_t[\tau_{t+j}] = \theta^j \tau_t$ 。代入求和公式：

$$\sum_{j=0}^{\infty} \delta^j (\theta^j \tau_t) = \tau_t \sum_{j=0}^{\infty} (\delta \theta)^j = \frac{1}{1 - \delta \theta} \tau_t$$

于是资本运动方程变为简化形式：

$$k_t = \lambda k_{t-1} - \underbrace{\frac{\alpha}{1 - \delta \theta}}_{\gamma} \tau_t$$

批判核心：回归系数 $\gamma = \frac{\alpha}{1 - \delta \theta}$ 明显依赖于政策参数 θ 。

- 如果政府改变政策（例如改变 θ ）， γ 也会随之改变。
- 若沿用旧数据的 γ 进行政策评估，必然得出错误的结论。